

**INSTITUTO FEDERAL DE EDUCAÇÃO, CIÊNCIA E TECNOLOGIA DO
MARANHÃO
CAMPUS CAXIAS**

FELIPE PEREIRA FERREIRA

**SISTEMA DE RECOMENDAÇÃO DE PRODUTOS PARA DISTRIBUIÇÃO B2B
UTILIZANDO REGRAS DE ASSOCIAÇÃO: ESTUDO DE CASO NA QUASAR
BARBER**

**CAXIAS – MA
2026**

FELIPE PEREIRA FERREIRA

**SISTEMA DE RECOMENDAÇÃO DE PRODUTOS PARA DISTRIBUIÇÃO B2B
UTILIZANDO REGRAS DE ASSOCIAÇÃO: ESTUDO DE CASO NA QUASAR
BARBER**

Trabalho de Conclusão de Curso
apresentado ao Curso de Bacharelado em
Ciências da Computação do Instituto Federal
de Educação, Ciência e Tecnologia do
Maranhão, Campus Caxias, como requisito
parcial para a obtenção do título de Bacharel
em Ciências da Computação.
Orientador: Prof. Me. François Barbosa.

CAXIAS – MA

2026

FELIPE PEREIRA FERREIRA

**SISTEMA DE RECOMENDAÇÃO DE PRODUTOS PARA DISTRIBUIÇÃO B2B
UTILIZANDO REGRAS DE ASSOCIAÇÃO: ESTUDO DE CASO NA QUASAR
BARBER**

Trabalho de Conclusão de Curso
apresentado ao Curso de Bacharelado em
Ciências da Computação do Instituto Federal
de Educação, Ciência e Tecnologia do
Maranhão, Campus Caxias, como requisito
parcial para a obtenção do título de Bacharel
em Ciências da Computação.

Aprovado em: _____ de _____ de 2026.

BANCA EXAMINADORA

Prof. Me. François Barbosa (Orientador)
Instituto Federal do Maranhão, Campus Caxias

Prof. (a) _____ (Examinador(a))
Instituto Federal do Maranhão, Campus Caxias

Prof. (a) _____ (Examinador(a))
Instituto Federal do Maranhão, Campus Caxias

RESUMO

Pequenos distribuidores B2B tomam decisões de venda casada de forma intuitiva, em um cenário com poucos clientes, sem avaliações de produtos e baixo volume transacional que torna inviável o uso de filtragem colaborativa tradicional. Este trabalho explora se regras de associação extraídas do histórico de vendas podem fornecer recomendações úteis e estatisticamente relevantes nesse cenário. Adotou-se o método *Design Science Research* para desenvolver e avaliar um sistema completo, com banco de dados, algoritmo de extração de regras, API REST e interface web, aplicado a dados reais da distribuidora Quasar Barber. Sobre 30 transações e 29 produtos, o sistema descobriu 44 regras, com confiança média de 76,51% e *lift* médio de 12,41. A qualidade preditiva foi estimada por validação cruzada *Leave-One-Out*, mais adequada a conjuntos pequenos do que o *holdout* simples, e alcançou *Recall* de 44,44% e *F1-Score* de 31,94%, valor coerente com o teto estrutural de *Precision* imposto pelo desenho de avaliação. As regras de maior *lift* mostraram aderência ao conhecimento de domínio do negócio. Conclui-se que as regras de associação são viáveis para recomendação em distribuição B2B de baixo volume, como apoio à decisão da equipe de vendas, ressalvada a escala reduzida do estudo.

Palavras-chave: Sistemas de recomendação. Regras de associação. Market Basket Analysis. Comércio B2B. Mineração de dados.

ABSTRACT

Small B2B distributors make cross-selling decisions intuitively, in a setting of few clients, no product ratings, and low transaction volume that renders traditional collaborative filtering unviable. This work investigates whether association rules extracted from sales history can produce useful and statistically relevant recommendations under those conditions. The Design Science Research method guided the development and evaluation of a complete system, comprising a database, a rule-extraction algorithm, a REST API, and a web interface, applied to real data from the distributor Quasar Barber. Across 30 transactions and 29 products, the system discovered 44 rules, with average confidence of 76.51% and average lift of 12.41. Predictive quality was estimated through Leave-One-Out cross-validation, better suited to small datasets than a simple holdout, reaching a Recall of 44.44% and an F1-Score of 31.94%, a value consistent with the structural precision ceiling imposed by the evaluation design. The rules with the highest lift agreed with the business domain knowledge. The results indicate that association rules are viable for recommendation in low-volume B2B distribution, serving as decision support for the sales team, subject to the study's limited scale

Keywords: Recommender systems. Association rules. Market Basket Analysis. B2B commerce. Data mining.

LISTA DE FIGURAS

Figura 1 – Arquitetura em camadas do sistema	28
Figura 2 – Diagrama entidade-relacionamento (ER) das tabelas qb_*	29
Figura 3 – Painel principal do sistema.....	34

LISTA DE QUADROS

Quadro 1 – Atividades da DSR aplicadas ao trabalho	22
Quadro 2 – Ferramentas e tecnologias empregadas	24
Quadro 3 – Tabelas do modelo de dados	28
Quadro 4 – <i>Endpoints</i> da API REST	32
Quadro 5 – Caracterização do conjunto de dados	38
Quadro 6 – Métricas globais do conjunto de regras	39
Quadro 7 – Resultados da validação cruzada <i>Leave-One-Out</i> (LOOCV)	40

LISTA DE TABELAS

Tabela 1 – Dez regras de maior <i>lift</i>	38
--	----

LISTA DE CÓDIGOS-FONTE

Código-fonte 1 – Recuperação e agrupamento das transações	30
Código-fonte 2 – Cálculo das métricas por par de produtos	31

SUMÁRIO

1 INTRODUÇÃO	12
1.1 Contextualização	12
1.2 Problema de pesquisa	12
1.3 Hipótese	13
1.4 Objetivos	14
1.4.1 Objetivo geral	14
1.4.2 Objetivos específicos.....	14
1.5 Justificativa.....	14
1.6 Delimitação do escopo	15
1.7 Organização do trabalho	15
2 FUNDAMENTAÇÃO TEÓRICA	16
2.1 Sistemas de recomendação	16
2.1.1 Definição e classificação	16
2.1.2 Filtragem colaborativa	16
2.1.3 Filtragem baseada em conteúdo	17
2.1.4 Abordagens híbridas	17
2.2 Regras de associação (<i>Market Basket Analysis</i>)	18
2.2.1 Conceito e conjuntos de itens	18
2.2.2 Algoritmo <i>Apriori</i>	18
2.2.3 Métricas: suporte, confiança e <i>lift</i>	19
2.3 O problema do cold start e da esparsidade	20
2.4 Comércio B2B e venda casada (<i>cross-sell</i>).....	21
2.5 Métricas de avaliação: <i>Precision</i> , <i>Recall</i> e <i>F1-Score</i>	21
2.6 Trabalhos relacionados	22
3 METODOLOGIA	22
3.1 Classificação da pesquisa	22
3.2 Design Science Research como método.....	23
3.3 Coleta e origem dos dados.....	24
3.4 Pré-processamento dos dados.....	24
3.5 Ferramentas e tecnologias	25
3.6 Protocolo de validação	26
3.6.1 Limitação do <i>holdout</i> simples	26
3.6.2 Validação cruzada <i>Leave-One-Out</i> (LOOCV)	27
3.6.3 Considerações sobre o teto da <i>Precision</i>	27
4 DESENVOLVIMENTO DO SISTEMA	28
4.1 Arquitetura geral.....	28
4.2 Modelagem de dados	29

4.3 Camada de dados e integração com o Supabase.....	30
4.4 Algoritmo de regras de associação	31
4.5 Geração de recomendações Top-N	32
4.6 API REST	32
4.7 Cache com degradação <i>graceful</i>	33
4.8 Interface web	33
4.9 Decisões de projeto e <i>trade-offs</i>	34
5 RESULTADOS E DISCUSSÃO	35
5.1 Caracterização do conjunto de dados	36
5.2 Regras descobertas e análise por <i>lift</i>	37
5.3 Métricas globais do conjunto de regras	38
5.4 Avaliação por <i>Precision</i> , <i>Recall</i> e <i>F1-Score</i>	39
5.4.1 Confronto com o <i>holdout</i> simples	39
5.5 Aderência ao conhecimento de domínio	40
5.6 Confronto com a hipótese de pesquisa	41
5.7 Limitações do estudo	41
6 CONCLUSÃO	42
6.1 Síntese das contribuições	42
6.2 Resposta à pergunta de pesquisa.....	43
6.3 Trabalhos futuros	44
REFERÊNCIAS.....	45

1 INTRODUÇÃO

1.1 Contextualização

O aumento da disponibilidade de dados tem feito com que a capacidade de convertê-los em conhecimento estratégico torne-se um verdadeiro diferencial competitivo para empresas de todos os portes. Sistemas de recomendação que utilizam técnicas de inteligência de dados, como histórico de vendas, são capazes de gerar sugestões úteis, que podem ser de qual o melhor produto a escolher, o que oferecer ao consumidor para aumentar o resultado comercial (RESNICK; VARIAN, 1997). Em distribuidoras regionais, no entanto, mostram uma mudança nesse cenário. Uma distribuidora frequentemente atende a um número limitado de clientes (outras empresas, e não o consumidor final), não coleta avaliações de produtos e apresenta um volume limitado de transações, se comparado ao varejo B2C. Faltam, assim, condições que tornam viável a filtragem colaborativa: a matriz usuário-item torna-se extremamente esparsa e o problema de cold start deixa de ser a exceção para se tornar a situação predominante.

É nesse contexto que se encontra a Quasar Barber, uma distribuidora de produtos para barbearia com sede em Codó, Maranhão, e de propriedade do próprio autor. Como a maioria das distribuidoras desse porte, as sugestões de venda cruzada e reposição são feitas de forma intuitiva, com base no conhecimento e experiência da equipe de vendas. Esse conhecimento é valioso, mas implícito: permanece nas mãos apenas dos vendedores de produtos, não escala com a operação e não pode ser auditado. Ao mesmo tempo, a empresa possui um histórico de pedidos que pode, quando analisado, revelar padrões de compras conjuntas que ainda não foram percebidos.

1.2 Problema de pesquisa

Distribuidoras B2B de pequeno e médio porte operam com um catálogo amplo, mas conduzem as decisões de *cross-sell* e de sugestão de reposição de forma intuitiva. Diferentemente do varejo B2C, esse cenário se caracteriza por poucos clientes. Pequenos e médios distribuidores B2B têm um vasto catálogo e fazem

sugestões de venda cruzada/reabastecimento de forma intuitiva. Ao contrário do varejo B2C, este cenário é caracterizado por poucos clientes, sem avaliações e classificações de produtos, e um volume transacional reduzido, condições que inviabilizam a filtragem colaborativa clássica, dependente de uma matriz usuário-item densa (SARWAR et al., 2001).

Assim, nosso trabalho é responder à seguinte pergunta

É possível gerar recomendações de produtos úteis e estatisticamente relevantes para uma distribuidora B2B de pequeno porte utilizando apenas regras de associação extraídas do histórico transacional, mesmo diante de um volume reduzido de transações?

Desdobram-se, a partir dela, três subperguntas:

1. Quais limiares de *support* e *confidence* produzem regras relevantes (não triviais) em um conjunto de dados esparsos, da ordem de dezenas de transações?
2. Como a métrica de *lift* distingue associações úteis de coocorrências por mero acaso nesse cenário?
3. Quais são as limitações de validação (*Precision*, *Recall* e *F1-Score*) quando o conjunto de teste contém poucas transações multi-item?

1.3 Hipótese

Em resposta à pergunta de pesquisa, propõe-se a seguinte hipótese de trabalho:

H1: regras de associação com *confidence* $\geq 0,30$ e *support* $\geq 0,02$, ranqueadas por *lift*, produzem recomendações de *cross-sell* coerentes com o conhecimento de domínio da distribuidora, mesmo em um conjunto de dados reduzido.

A ela contrapõe-se a hipótese nula:

H0: em volume transacional reduzido, as regras geradas são indistinguíveis de coocorrências aleatórias e não superam uma recomendação baseada apenas nos produtos mais vendidos (*baseline* de popularidade).

1.4 Objetivos

1.4.1 Objetivo geral

Desenvolver e validar um sistema de recomendação de produtos B2B baseado em regras de associação (*Market Basket Analysis*), aplicado ao histórico de vendas da Quasar Barber, capaz de sugerir produtos complementares com relevância estatística mensurável.

1.4.2 Objetivos específicos

1. Revisar a literatura sobre sistemas de recomendação, regras de associação (*Apriori*) e as métricas *support*, *confidence* e *lift*.
2. Modelar uma base de dados transacional (PostgreSQL/Supabase) que represente clientes, produtos, vendas e itens de venda da distribuidora.
3. Implementar o algoritmo de extração de regras de associação e a geração de recomendações *Top-N* em uma API REST (Node.js/Express).
4. Construir uma interface web (*React*) que permita consultar recomendações por produto e visualizar métricas e gráficos das regras descobertas.
5. Validar a qualidade das recomendações por meio de validação cruzada *Leave-One-Out* (LOOCV), calculando *Precision*, *Recall* e *F1-Score*, e discutir as limitações impostas pelo tamanho do conjunto de dados.
6. Analisar as regras de maior *lift* sob a ótica de negócio, verificando sua aderência ao conhecimento de domínio.

1.5 Justificativa

À primeira vista, este trabalho é relevante tanto em um sentido acadêmico quanto prático e técnico.

Do ponto de vista acadêmico, a maioria dos estudos sobre sistemas de recomendação é em cenários de alto volume B2C, como Amazon e Netflix (LINDEN; SMITH; YORK, 2003; KOREN; BELL; VOLINSKY, 2009). No entanto, há pouca literatura sobre cenários B2B de baixo volume onde os dados são escassos e uma abordagem tradicional não é confiável. Este artigo é, portanto, uma tentativa de mostrar empiricamente como regras de associação podem ser usadas nesses tipos

de situações. Ao usar sugestões de produtos baseadas em dados, a empresa é capaz de entender melhor as estratégias de venda cruzada e se beneficiará de um processo de recomendação de produtos mais preciso, o que, por sua vez, aumentará o ticket médio e permitirá que a equipe de vendas se mantenha atualizada.

Em um nível técnico, mostramos que podemos criar uma arquitetura escalável e de baixo custo com ferramentas como Supabase e Node.js. Ao contrário de abordagens que pressupõe processamento distribuído (MORAES, 2023), nossa abordagem é baseada em recursos modestos, o que a torna mais viável.

1.6 Delimitação do escopo

O estudo se restringe a apenas um sistema de recomendação baseado em regras de associação extraídas do histórico transacional do Quasar Barber. Filtragem colaborativa, modelos de *deep learning* e recomendação em tempo real durante o *checkout* não são abordados. O conjunto de dados é uma série de pedidos que coletamos de abril a junho de 2026 (30 transações e 29 produtos). Esta é uma escala menor (mais gerenciável) e é a principal limitação e o objetivo do trabalho. Quanto à escolha da extração de regras par-a-par em vez da forma completa do algoritmo *Apriori* multi-item, esta é uma escolha feita no Capítulo 4 porque o conjunto de dados é bastante grande, e pretende gerar recomendações *Top-N* para produtos individuais.

1.7 Organização do trabalho

Além desta introdução, a monografia organiza-se em mais cinco capítulos:

- O Capítulo 2, Fundamentação Teórica. Revisamos sistemas de recomendação e sua taxonomia, regras de associação e o algoritmo *Apriori*, métricas de suporte, *confidence* e *lift*, problema de *cold start* e esparsidade, *cross-sell* no comércio B2B, métricas de avaliação e mais.
- O Capítulo 3, Metodologia. Classifica a pesquisa, apresenta o método *Design Science Research*, descreve a coleta e pré-processamento de dados, ferramentas adotadas e protocolo de validação.
- O Capítulo 4, Desenvolvimento do Sistema. Descrevemos a arquitetura, modelagem de dados, implementação do algoritmo, geração de recomendações, API REST, camada de *cache* e interface web.

- O Capítulo 5, Resultados e Discussão. Descrevemos o conjunto de dados, exploramos as regras descobertas, comparamos com as métricas globais e de avaliação, discutimos a hipótese e discutimos as limitações.
- O Capítulo 6, Conclusão, sintetiza as contribuições, responde à pergunta de pesquisa e aponta trabalhos futuros.

2 FUNDAMENTAÇÃO TEÓRICA

Este capítulo apresenta o quadro teórico para o desenvolvimento e avaliação do sistema proposto. Primeiro, descreve e categoriza sistemas de recomendação (Seção 2.1) e, em seguida, regras de associação e o algoritmo Apriori (Seção 2.2). Depois, discute o problema do *cold start* e a esparsidade (Seção 2.3) para justificar a escolha metodológica deste trabalho e a venda cruzada no comércio B2B (Seção 2.4) e métricas de avaliação de recomendação (Seção 2.5). Finalmente, o capítulo conclui com trabalhos relacionados (Seção 2.6).

2.1 Sistemas de recomendação

2.1.1 Definição e classificação

Sistemas de recomendação são ferramentas e métodos de software que fornecem recomendações de itens potencialmente úteis a um usuário (RICCI; ROKACH; SHAPIRA, 2015). O termo sistemas de recomendação foi cunhado por Resnick e Varian (1997) como um mecanismo que pode auxiliar e aprimorar o processo social de recomendação, no qual as pessoas aceitam recomendações de terceiros quando têm um número esmagador de opções. Adomavicius e Tuzhilin (2005) caracterizam o problema de recomendação como a estimativa de uma função de utilidade que, para um usuário e um item ainda não considerado, prevê quão relevante o item será para o usuário. A partir dessa definição, os autores desenvolveram uma classificação que agora se tornou um

padrão na pesquisa e que possui três abordagens principais: filtragem colaborativa, filtragem baseada em conteúdo e métodos híbridos.

2.1.2 Filtragem colaborativa

A filtragem colaborativa recomenda itens com base em usuários semelhantes, partindo da premissa de que pessoas que concordaram no passado tenderão a concordar no futuro (SARWAR et al., 2001). A principal entrada é uma matriz usuário-item na qual cada célula conta se um usuário avaliou (explicitamente) ou interagiu com um item.

Existem duas vertentes principais. A filtragem colaborativa baseada em usuários procura vizinhos semelhantes a eles. No caso de Sarwar et al. (2001), e popularizada pela Amazon (LINDEN; SMITH; YORK, 2003), em termos de semelhanças entre itens e se tornou mais escalável. Mais recentemente, técnicas de fatoração de matrizes se tornaram o padrão da indústria após o Prêmio Netflix, ao decompor a matriz usuário-item em fatores latentes que capturam preferências não observáveis diretamente (KOREN; BELL; VOLINSKY, 2009).

O ponto chave aqui é que toda filtragem colaborativa requer uma matriz usuário-item robusta. Se houver poucos usuários, poucos itens avaliados por usuário ou nenhuma avaliação, a similaridade entre usuários ou itens será muito fraca e difícil de calcular (SARWAR et al., 2001). Esta é exatamente a situação no caso de baixo volume B2B considerado nesta monografia.

2.1.3 Filtragem baseada em conteúdo

A filtragem baseada em conteúdo oferece itens exatamente semelhantes aos que o usuário gostou no passado, com base nos atributos dos próprios itens (categoria, marca, descrição textual, características técnicas, etc.) (ADOMAVICIUS; TUZHILIN, 2005). Um perfil de usuário é construído em torno dos atributos dos itens com os quais ele interagiu, e novos itens cujos conteúdos estão próximos a esse perfil são sugeridos. Essa abordagem não inclui dados de outros usuários; portanto, não é propensa à esparsidade. Em contrapartida, tende à superespecialização: sugere apenas “mais do mesmo” e não permite a descoberta de itens complementares de diferentes categorias, justamente o tipo de associação que interessa ao *cross-sell* (AGGARWAL, 2016). Além disso, requer

uma representação rica e estruturada dos atributos dos produtos, o que nem sempre está disponível em catálogos de pequenos distribuidores.

2.1.4 Abordagens híbridas

Abordagens híbridas combinam duas ou mais técnicas para superar as limitações individuais de cada uma, como conteúdo para contornar *cold start* da filtragem colaborativa (ADOMAVICIUS; TUZHILIN, 2005; RICCI; ROKACH; SHAPIRA, 2015). Embora possam ter um desempenho melhor, são mais complexas e requerem dados para serem implementadas e, portanto, não são adequadas para o escopo do presente trabalho. Também é importante notar que regras de associação, que estão no cerne desta monografia, são um tipo diferente de abordagem das três anteriores, pois não dependem constituem uma abordagem distinta das três anteriores: não dependem de perfis de usuário individuais, mas de padrões de coocorrência no conjunto das transações (AGGARWAL, 2016).

2.2 Regras de associação (Market Basket Analysis)

2.2.1 Conceito e conjuntos de itens

As regras de associação foram introduzidas por Agrawal, Imieliński e Swami (1993) para determinar as relações entre itens em grandes bases de dados transacionais, também conhecidas como *Market Basket Analysis* (análise da cesta de compras). A questão era simples: quais produtos os clientes de supermercado tendem a comprar juntos?

Formalmente, seja $I = \{i_1, i_2, \dots, i_m\}$ um conjunto de itens e D um conjunto de transações onde $T \subseteq I$. Um conjunto de itens é qualquer subconjunto de I e um conjunto de itens com k elementos é chamado de k -conjunto de itens. Uma regra de associação é uma implicação da forma $X \Rightarrow Y$, onde $X \subset I$, $Y \subset I$, e $X \cap Y = \emptyset$. O conjunto X é o antecedente e Y , o conseqüente da regra (AGRAWAL;

IMIELIŃSKI; SWAMI, 1993). Lê-se: “transações contendo X tendem a também ter Y,” por exemplo, {Leite} $\Rightarrow$ {Pão}.

2.2.2 Algoritmo Apriori

O número de conjuntos de itens candidatos cresce exponencialmente com o número de itens, o que inviabiliza a contagem por força bruta. O algoritmo *Apriori*, proposto por Agrawal e Srikant (1994), contorna esse problema explorando uma propriedade de antimonotonicidade conhecida como princípio *Apriori*: se um *itemset* é frequente, todos os seus subconjuntos também são; se um *itemset* é infrequente, nenhum de seus subconjuntos será frequente.

Essa propriedade permite podar o espaço de busca, pois, uma vez identificado um conjunto de itens sem suporte mínimo, ele pode ser descartado sem que suas extensões precisem ser contadas (TAN; STEINBACH; KUMAR, 2005, p. 333). O algoritmo procede da seguinte forma:

1. Definir o suporte mínimo e a confiança mínima para os *itemsets*.
2. Encontrar os *itemsets* frequentes: comece com os itens individuais e calcule seu suporte; depois combine pares, trios e assim por diante, para que apenas os conjuntos de itens com o suporte máximo sejam mantidos.
3. Gerar as regras: a partir dos *itemsets* frequentes, derivam-se regras $X \Rightarrow Y$.
4. Avaliar as regras pelas métricas de suporte, confiança e *lift*, retendo apenas as que excedem os limiares definidos.

O resultado é um conjunto de regras fortes que revelam padrões de compra úteis e descartam coincidências e trivialidades. *Apriori* foi um dos mais populares entre esses algoritmos, ganhando o Prêmio VLDB de 10 anos em 2004.

Apesar de ser comparativamente eficiente, *Apriori* faz várias varreduras no banco de dados e gera um grande número de candidatos. Em 2000, Han, Pei e Yin (2000) propuseram um algoritmo *FP-Growth*, que minera padrões frequentes sem geração de candidatos, por meio de uma estrutura compacta em árvore (*FP-tree*), com desempenho até uma ordem de grandeza superior. Para o conjunto de dados limitado deste artigo, a eficiência assintótica não é garantida, mas

continuaremos a discuti-la no Capítulo 4, onde apresentamos a estratégia de dois lados.

2.2.3 Métricas: suporte, confiança e *lift*

Três métricas medem a relevância de uma regra de associação (AGRAWAL; IMIELIŃSKI; SWAMI, 1993; HAHSLER; GRÜN; HORNIK, 2005). O suporte mede a frequência com que o conjunto de itens aparece no conjunto de transações. Para uma regra $X \Rightarrow Y$:

$$\text{support}(X \Rightarrow Y) = \frac{|\{T \in D : X \cup Y \subseteq T\}|}{|D|} \quad (2.1)$$

Ele indica o quão comum é a combinação. Um suporte de 20% significa que 20% de todas as transações contêm, ao mesmo tempo, X e Y.

A confiança mede a probabilidade condicional de o conseqüente ocorrer dado que o antecedente ocorreu:

$$\text{confidence}(X \Rightarrow Y) = \frac{\text{support}(X \cup Y)}{\text{support}(X)} = P(Y | X) \quad (2.2)$$

Uma confiança de 70% para $\{\text{Manteiga}\} \Rightarrow \{\text{Pão}\}$ indica que, entre as transações que contêm leite, 70% também contêm pão.

O *lift* (elevação) mede a força da associação em relação ao que se esperaria caso X e Y fossem independentes:

$$\text{lift}(X \Rightarrow Y) = \frac{\text{confidence}(X \Rightarrow Y)}{\text{support}(Y)} = \frac{P(X \cap Y)}{P(X) \cdot P(Y)} \quad (2.3)$$

A interpretação do *lift* é estratégica para distinguir associações úteis de coincidências (BRIN et al., 1997):

- *lift* = 1: X e Y são independentes, e a coocorrência é fruto do acaso;
- *lift* > 1: associação positiva, em que a presença de X aumenta a probabilidade de Y;
- *lift* < 1: associação negativa, em que a presença de X diminui a probabilidade de Y.

A confiança sozinha pode ser enganosa: um consequente muito popular gera alta confiança mesmo sem uma relação real com o antecedente. O *lift* corrige isso normalizando pela popularidade do consequente e é por isso que é usado como critério de classificação neste trabalho.

2.3 O problema do *cold start* e da esparsidade

O *cold start* é quando um sistema de recomendação falha em fornecer uma sugestão confiável quando não há informações, seja sobre um novo usuário, um novo item ou todo um sistema recém-implantado (ADOMAVICIUS; TUZHILIN, 2005). É um problema endêmico da filtragem colaborativa, e sem avaliações passadas não há base para medir semelhanças. A esparsidade é relacionada e ainda mais estrutural. Em sistemas reais, a matriz usuário-item geralmente é preenchida em uma pequena fração, pois cada usuário interage com uma parcela pequena do catálogo, o que enfraquece as estimativas de similaridade (SARWAR et al., 2001). Em situações de baixo volume B2B, a esparsidade atinge níveis extremos, com poucos clientes, sem avaliações e dezenas, mas não milhões, de transações.

É então que as regras de associação revelam sua vantagem. Seu foco está nos padrões de coocorrência do conjunto de transações e não nos perfis de usuários, dispensam a matriz usuário-item densa e contornam parte significativa do problema de esparsidade interusuário (AGGARWAL, 2016). Esta é a principal razão para a metodologia desta monografia, descrita no Capítulo 3

2.4 Comércio B2B e venda casada (*cross-sell*)

O comércio *business-to-business* (B2B) se caracteriza por transação entre empresas, no caso deste trabalho, entre uma distribuidora e barbearias clientes. Distingue-se do B2C por ter relações de longo prazo, poucos clientes, compras repetidas e sem avaliações típicas de produtos no varejo eletrônico.

A venda cruzada, ou *cross-sell*, consiste em sugerir, no momento da compra, produtos complementares aos que o cliente já adquiriu (SCHAFER; KONSTAN; RIEDL, 2001). É exatamente o tipo de recomendação que as regras de associação fazem: descobrir que clientes que compram o produto X também tendem a comprar Y é exatamente o que chamaríamos de sugestão de venda

cruzada. Linden, Smith e York (2003) analisaram o impacto econômico dessa estratégia para a Amazon no mercado de varejo de massa. Neste trabalho, levamos isso para o B2B de pequena escala, onde o conhecimento de quais produtos são vendidos juntos hoje reside apenas na intuição da equipe de vendas.

2.5 Métricas de avaliação: *Precision*, *Recall* e *F1-Score*

Além das métricas internas das regras (*suporte*, *confidence* e *lift*), precisamos testar o poder preditivo das recomendações. Para isso, adotamos as métricas clássicas de recuperação de informação, formalizada por Powers (2011).

Dado um conjunto de recomendações, os resultados são classificados como verdadeiros positivos (TP, recomendações corretas), falsos positivos (FP, recomendações incorretas) e falsos negativos (FN, itens relevantes não recomendados). Define-se:

$$\text{Precision} = \frac{VP}{VP + FP} \quad (2.4)$$

$$\text{Recall} = \frac{VP}{VP + FN} \quad (2.5)$$

Respostas de *Precision*: das recomendações feitas, quantas estavam corretas? Respostas de *recall*: dos itens que deveriam ter sido recomendados, quantos o sistema acertou? Há uma tensão entre os dois: maximizar um tende a degradar o outro.

O *F1-Score* equilibra ambos através da média harmônica:

$$F1 = 2 \cdot \frac{\text{Precision} \cdot \text{Recall}}{\text{Precision} + \text{Recall}} \quad (2.6)$$

A média harmônica penaliza desequilíbrios: o *F1-Score* só é alto quando tanto a *Precision* quanto o *Recall* são razoavelmente altos. Powers (2011) alerta, no entanto, que esses valores devem ser interpretados à luz do tamanho e da composição do conjunto de teste, uma advertência particularmente pertinente

para este trabalho, cujo conjunto de validação é limitado e contém poucas transações de múltiplos itens, conforme apresentado no Capítulo 5.

2.6 Trabalhos relacionados

A aplicação de regras de associação a dados transacionais de varejo tem uma longa história na literatura de estudos nacionais e internacionais. Schonhorst (2010) aplicou a mineração de regras de associação a dados transacionais de um supermercado brasileiro para descobrir padrões de compra em varejo de médio porte e a análise foi semelhante à desta monografia (B2C), embora em um contexto B2B.

Schafer, Konstan e Riedl (2001) sistematizaram aplicações de recomendação em *e-commerce* com base em dados de recomendação e situam o *cross-sell* baseado na coocorrência de estratégias clássicas, ao passo que Linden, Smith e York (2003) documentaram o caso emblemático da Amazon. Esses trabalhos mostram que essa técnica é de fato madura no varejo de alto volume e também mostram a lacuna que esta monografia se propõe abordar, a saber, quão bem as regras de associação podem funcionar na distribuição B2B de baixo volume, recorte ainda pouco explorado na literatura.

3 METODOLOGIA

3.1 Classificação da pesquisa

Quanto à natureza, esta pesquisa classifica-se como aplicada, pois trata-se de conhecimento para resolver um problema real: o apoio à decisão de venda casada em uma distribuidora B2B real (GIL, 2017; MARCONI; LAKATOS, 2017). É de natureza quantitativa, pois são utilizadas métricas estatísticas para validar as regras de associação extraídas.

Do ponto de vista dos objetivos, a pesquisa é exploratória e descritiva. Visa estudar a viabilidade de uma técnica em um caso relativamente novo no mercado B2B de baixo volume transacional e como os padrões de coocorrência são exibidos nos dados. Em termos de pesquisa técnica, isso é feito usando um

estudo de caso do distribuidor Quasar Barber. Como Yin (2015) observou, o estudo de caso é adequado para estudar fenômenos contemporâneos em seu contexto real, e permite uma análise aprofundada das transações B2B e da eficácia dessas recomendações.

3.2 Design Science Research como método

Diferentemente das ciências naturais, que buscam explicar fenômenos existentes, a *Design Science Research* (DSR) orienta-se à construção e à avaliação de artefatos que resolvem problemas reais e produz conhecimento por meio do próprio ato de projetar (HEVNER et al., 2004). Nesse contexto, o DSR é mais adequado para criar um sistema computacional que resolva um problema com uma necessidade na organização. Peffers et al. (2007) fornece uma operacionalização do DSR que a separa em seis atividades principais. O Quadro 1 mostra como cada atividade é implementada nesta monografia.

Quadro 1 — Atividades da DSR aplicadas ao trabalho

Atividade (PEFFERS et al., 2007)	Concretização neste trabalho
1. Identificação do problema e motivação	Decisões de <i>cross-sell</i> tomadas de forma intuitiva em distribuidora B2B de baixo volume (Capítulo 1).
2. Definição dos objetivos da solução	Gerar recomendações <i>Top-N</i> estatisticamente relevantes a partir do histórico transacional (Seção 1.4).
3. Projeto e desenvolvimento	Sistema completo: banco de dados, algoritmo de regras de associação, API REST e interface web (Capítulo 4).
4. Demonstração	Execução do sistema sobre os dados reais de vendas de 2026 da Quasar Barber.
5. Avaliação	Cálculo de <i>Precision</i> , <i>Recall</i> e <i>F1-Score</i> por validação cruzada <i>Leave-One-Out</i> (LOOCV), além da análise das regras por <i>lift</i> (Capítulo 5).
6. Comunicação	Esta monografia e a sua defesa perante a banca.

Fonte: elaborada pelo autor (2026).

3.3 Coleta e origem dos dados

Os dados utilizados são transações reais de vendas da Quasar Barber, uma distribuidora de produtos para barbearias em Codó, Maranhão. Os dados correspondem aos pedidos recebidos do sistema de gestão da empresa entre 29 de abril e 18 de junho de 2026, que são exportados para um arquivo CSV (*comma-separated values*, com ponto e vírgula como separador).

Cada linha do arquivo bruto contém um item de pedido e os campos número do pedido, data, cliente, produto, quantidade e preço unitário. Pedidos com mais de um produto ocupam, portanto, várias linhas que compartilham o mesmo número de pedido. Essa estrutura é exatamente a exigida pela *Market Basket Analysis*, em que cada pedido constitui uma transação (cesta) e os produtos nela contidos formam o *itemset* observado (AGRAWAL; IMIELIŃSKI; SWAMI, 1993).

Após o pré-processamento descrito na Seção 3.4, o conjunto final tem 30 transações, 26 clientes e 29 produtos únicos no total, para um total de 52 itens de vendas. 14 transações contêm dois ou mais produtos, e essas são as cestas mais úteis para entender as regras de coocorrência. As outras, com apenas um item, contribuem para o cálculo do suporte individual dos produtos, mas não produzem regras em si. Esse baixo volume é típico do cenário B2B que estamos estudando e tem um efeito direto na validação, que será discutido na Seção 3.6 e no Capítulo 5.

Como todos esses dados são da própria empresa do autor e foram usados em conjunto e sem revelar informações pessoais sensíveis dos consumidores finais, não houve necessidade de submissão a comitê de ética; os nomes de clientes (pessoas jurídicas e compradores) são usados apenas como identificadores de transação no processamento.

3.4 Pré-processamento dos dados

O arquivo bruto exportado não está imediatamente pronto para a mineração: requer limpeza e transformação. As etapas de pré-processamento, implementadas em um *script* de carga (*seed-csv.js*, detalhado na Seção 4.2), são as seguintes:

1. Normalização de codificação. O arquivo de origem apresentava codificação inconsistente (mistura de *Latin-1* e UTF-8), o que corrompia caracteres

acentuados. Padronizou-se todo o texto em UTF-8, com transliteração dos acentos para ASCII, a fim de garantir uniformidade na comparação de nomes de produtos.

2. Validação de integridade transacional. Verificou-se que cada número de pedido correspondesse a um único cliente e a uma única data. Inconsistências em que um mesmo número agregava clientes distintos, e que produzem cestas artificiais e regras espúrias, foram corrigidas com a separação dos pedidos.

3. Agrupamento por pedido. As várias linhas de item foram agrupadas pelo número do pedido, o que reconstitui cada transação como um conjunto de produtos (a cesta).

4. Deduplicação intratransação. Quando um mesmo produto aparecia repetido na mesma cesta, as ocorrências foram consolidadas, somando-se as quantidades, de modo que cada produto figure uma única vez por transação, condição necessária para o cálculo correto do suporte.

5. Inferência de categoria. Para fins de análise e exibição, cada produto foi classificado em uma de três categorias (*Barba*, *Cabelo* ou *Acessórios*) por meio de regras heurísticas sobre palavras-chave do nome (por exemplo, a presença de “barba”, “*balm*” ou “*after shave*” indica a categoria *Barba*).

6. Conversão de formatos. As datas, originalmente no padrão brasileiro DD/MM/AAAA, foram convertidas para o padrão ISO AAAA-MM-DD exigido pelo banco de dados, e os valores monetários foram normalizados para ponto decimal.

O produto dessas etapas é um conjunto de transações limpo e consistente, carregado nas tabelas relacionais descritas no Capítulo 4.

3.5 Ferramentas e tecnologias

A escolha tecnológica foi por ferramentas gratuitas ou de baixo custo, com reproduíveis e adequadas ao porte de uma pequena empresa (Seção 1.5) que estavam alinhadas com a justificativa técnica do nosso trabalho. O Quadro 2 sintetiza a *stack* adotada.

Quadro 2 — Ferramentas e tecnologias empregadas

Camada	Tecnologia	Função
Linguagem	JavaScript (Node.js 18)	Lógica do <i>back-end</i> e do algoritmo
Framework web	Express	Roteamento e exposição da API REST

Camada	Tecnologia	Função
Banco de dados	PostgreSQL via Supabase	Persistência das transações
Acesso a dados	Supabase JS / PostgREST	Consultas via API REST sobre o banco
Cache	Redis (opcional)	Memoização das regras calculadas
Front-end	React 18 + Vite	Interface web e <i>build</i>
Visualização	Chart.js	Gráficos das regras e métricas
Testes	Jest + Supertest	Testes unitários e de integração

Fonte: elaborada pelo autor (2026).

A escolha do Supabase como plataforma de banco de dados deve-se à oferta de um PostgreSQL gerenciado em camada gratuita, com acesso via API REST (*PostgREST*), o que dispensa a manutenção de servidor próprio. O *cache* em Redis é tratado como dependência opcional: na sua ausência, o sistema recalcula as regras a cada requisição, o que degrada o desempenho, mas preserva a exatidão, decisão de projeto detalhada na Seção 4.7.

3.6 Protocolo de validação

A avaliação da qualidade das recomendações utiliza três métricas tradicionais de recuperação de informação: *Precision*, *Recall* e *F1-Score* (POWERS, 2011), e essa abordagem é descrita na Seção 2.5. Porém, a forma de avaliá-las precisa acomodar a principal limitação deste estudo: o pequeno número de transações.

3.6.1 Limitação do *holdout* simples

A abordagem mais comum, o *holdout* por divisão de treino/teste (por exemplo, 80% para treinamento e 20% para teste foi inicialmente implementado para referenciar essa abordagem. No entanto, em um conjunto de dados de 30 transações, e os 20% reservados ao teste correspondem a apenas seis transações, das quais somente as multi-item permitem avaliação efetiva, na prática, três transações avaliáveis. Se estimarmos um conjunto de casos com base em apenas

6, é muito instável porque a inclusão ou remoção de uma transação tem um grande efeito no resultado e a medida não é confiável.

3.6.2 Validação cruzada *Leave-One-Out* (LOOCV)

Para lidar com essa limitação, escolhemos a validação *Leave-One-Out* (LOOCV), recomendada para conjuntos de dados pequenos por aproveitar ao máximo a informação disponível (HAN; KAMBER; PEI, 2011). Em vez de uma partição, conduzimos N rodadas, onde N é o número de transações; em cada rodada definimos uma transação para teste, e o algoritmo é treinado com as $N - 1$ restantes. Assim, cada transação é apenas um teste e o modelo é treinado com o máximo (o máximo de dados possível).

Em cada transação de teste, aplica-se o esquema de ocultação de um item (*leave-one-out* interno): de uma cesta com k produtos, oculta-se um produto por vez e apresentam-se os $k - 1$ restantes como antecedentes. Então, o algoritmo gera as recomendações *Top-N* a partir das regras de treinamento e verifica se o produto oculto está entre os sugeridos. A cesta de k produtos então cria k subtestes. As métricas são calculadas sobre o conjunto de todos os subtestes acumulados nas N rodadas. Formalmente, para cada subteste, temos onde R é o conjunto de produtos recomendados e $\{p\}$ é o produto oculto (a verdade de referência):

$$\text{Precision} = \frac{|R \cap \{p\}|}{|R|}, \quad \text{Recall} = \frac{|R \cap \{p\}|}{|\{p\}|} \quad (3.1)$$

3.6.3 Considerações sobre o teto da *Precision*

Cabe registrar uma propriedade do esquema de ocultação de um único item: como há exatamente um produto a recuperar e o sistema recomenda até N produtos (com $N = 3$), o valor máximo de *Precision* para um subteste bem-sucedido é $1/N \approx 0,33$. A *Precision* é estruturalmente limitada neste design e deve ser entendida em termos deste teto. *Recall* e *F1-Score* tornam-se, assim, os melhores indicadores da capacidade de o sistema completar a cesta. Esta interpretação é revisitada na análise dos resultados (Capítulo 5).

Os parâmetros definidos no algoritmo de validação são os mesmos do sistema, ou seja, confiança mínima de 0,30, suporte mínimo de 0,02, *lift* mínimo de 1,0 e $N = 3$ recomendações. A razão para esses limiares e os resultados são apresentados no Capítulo 5.

4 DESENVOLVIMENTO DO SISTEMA

Este capítulo descreve o artefato construído, a realização da atividade de “projeto e desenvolvimento” da DSR (Seção 3.2). Define a arquitetura geral (Seção 4.1), modelagem de dados (Seção 4.2), a camada de integração com o banco de dados (Seção 4.3), implementação do algoritmo de regras de associação (Seção 4.4) e recomendações *Top-N* (Seção 4.5), API REST (Seção 4.6), *cache* (Seção 4.7), interface web (Seção 4.8) e, finalmente, as principais decisões de design e seu impacto (Seção 4.9).


4.1 Arquitetura geral

Temos uma arquitetura em camadas de modo que nenhuma responsabilidade é atribuída ao cliente, servidor ou persistência. O fluxo de requisição segue os seguintes passos:

Cliente (React) → API REST (Express) → Serviços → Camada de dados (Models) → Banco (Supabase/PostgreSQL)

A interface web (*front-end*), construída em React, é baseada em uma API REST que é exposta ao servidor de mídia *Node.js/Express* (*back-end*). O servidor é estruturado em três camadas: as rotas, que recebem requisições HTTP e validam parâmetros, serviços, que se concentram na lógica de negócios (o algoritmo de recomendação, a validação e o *cache*); e os modelos (*models*), que isolam todo o acesso ao banco de dados. Essa estratificação permite que uma mudança no banco de dados, ou até mesmo uma mudança na plataforma de persistência, afete apenas a camada de modelos e não as rotas ou a interface.

Figura 1 — Arquitetura em camadas do sistema



Fonte: elaborada pelo autor (2026).

4.2 Modelagem de dados

O modelo de dados relacional representa o domínio da distribuidora em quatro tabelas, prefixadas por qb_ para padroniza-las dentro do projeto Supabase. O Quadro 3 descreve cada entidade.

Quadro 3 — Tabelas do modelo de dados

Tabela	Descrição	Principais campos
qb_clientes	Barbearias e compradores atendidos pela distribuidora	id, nome_loja, cidade, estado
qb_produtos	Catálogo de produtos	id, nome, categoria, preco, ativo
qb_vendas	Cabeçalho de cada venda (transação)	id, cliente_id, data, valor_total, metodo_pagamento
qb_itens_venda	Itens que compõem cada venda	id, venda_id, produto_id, quantidade, valor_unitario


Fonte: elaborada pelo autor (2026).

O relacionamento central liga qb_vendas a qb_itens_venda (um-para-muitos: uma venda contém vários itens) e qb_itens_venda a qb_produtos (muitos-para-um: cada item referencia um produto). É justamente o par (venda_id, produto_id) que

materializa a noção de “produto presente em uma cesta”, insumo direto da *Market Basket Analysis*.

Figura 2 — Diagrama entidade-relacionamento (ER) das tabelas qb_*

Cardinalidade: um cliente tem N vendas; uma venda tem N itens; cada item referencia 1 produto.
O par (venda_id, produto_id) materializa “produto presente na cesta” — insumo da Market Basket Analysis.



Fonte: elaborada pelo autor (2026).

A carga dos dados pré-processados (Seção 3.4) no banco é realizada por um *script* dedicado, *seed-csv.js*, realiza a limpeza dos itens, os agrupa por ordem, os divide em categorias, insere clientes e produtos de maneira consistente (sem duplicatas) e, em seguida, registra vendas e itens. O *script* oferece até mesmo um *reset* completo das tabelas, o que é necessário ao substituir o conjunto de dados por uma exportação atualizada.

4.3 Camada de dados e integração com o Supabase

O banco de dados é acessível através do cliente *JavaScript* do *Supabase*, que é construído sobre o *PostgREST*, uma API REST para PostgreSQL. Esta rota foi escolhida em vez de uma conexão SQL direta porque o nível gratuito do *Supabase* fornece acesso REST com uma chave pública (*anon key*), que preenche a lacuna das operações de leitura exigidas pelo algoritmo sem quaisquer credenciais de conexão e *pool*.

A consulta mais importante da camada de modelo é aquela que recupera todas as transações de acordo com o formato que o algoritmo requer. O PostgREST conecta `qb_itens_venda` e `qb_produtos` usando a chave estrangeira e retorna uma linha por transação. Em seguida, agrupamos as transações por venda na memória e reconstruímos cada transação como o objeto com vetor de itens (Código Fonte 1).

Código-fonte 1 — Recuperação e agrupamento das transações (models/index.js)

```
async function buscarVendas() {
  const { data, error } = await supabase
    .from('qb_itens_venda')
    .select(`venda_id, quantidade, valor_unitario,
            qb_produtos (id, nome, categoria)`);
  if (error) throw new Error(error.message);

  const vendasMap = {};
  for (const item of data) {
    if (!vendasMap[item.venda_id]) {
      vendasMap[item.venda_id] = { id: item.venda_id, itens: [] };
    }
    vendasMap[item.venda_id].itens.push({
      nome_produto: item.qb_produtos.nome,
      produto_id: item.qb_produtos.id,
      categoria: item.qb_produtos.categoria,
    });
  }
  return Object.values(vendasMap);
}
```

Fonte: elaborada pelo autor (2026).

As tabelas são protegidas com RLS (*Row Level Security*): a chave pública oferece acesso somente leitura, enquanto a chave de serviço privada está disponível apenas no ambiente do servidor e nunca é conhecida pelo cliente.

4.4 Algoritmo de regras de associação

No núcleo do nosso sistema está a função *calculateAssociation*. É uma versão simplificada da extração de regras de associação que só aceita regras com um item no antecedente e um item no consequente ($A \Rightarrow B$) como entrada.

Isso é feito para evitar complexidade e é a solução lógica para um conjunto de dados com várias transações: se o número de itens em A e B for grande, então as regras devem ser muito baixas para serem confiáveis, e o custo computacional associado à geração par a par é negligenciável (discussão na Seção 4.9).

Para cada par de produtos (A e B), o algoritmo conta as transações com A, aquelas com A e B, e as transações com B, e calcula as três métricas que discutimos na Seção 2.2.3: *suporte*, *confidence* e *lift*. Apenas as regras que simultaneamente satisfazem os limiares mínimos de confiança e suporte são retidas. O Código Fonte 2 reproduz o núcleo deste processamento.

**Código-fonte 2 — Cálculo das métricas por par de produtos
(services/recomendacao.js)**

```
const confidence = transacoesComAeB.length / transacoesComA.length;
const support    = transacoesComAeB.length / totalTransacoes;

if (confidence >= minConfidence && support >= minSupport) {
  const supportB = transacoesComB.length / totalTransacoes;
  const lift = supportB > 0 ? confidence / supportB : 0;
  regras.push({
    antecedente: produtoA, consequente: produtoB,
    confidence, support, lift,
    frequencia: transacoesComAeB.length,
  });
}
```

Fonte: elaborada pelo autor (2026).

Os limiares são centralizados em um único arquivo de configuração, com os valores definidos para o estudo: confiança mínima de 0,30, suporte mínimo de 0,02, *lift* mínimo de 1,0 e número de recomendações *Top-N* igual a 3. A escolha desses valores e seu efeito sobre o conjunto de regras são analisados no Capítulo 5. Ao final, as regras são ordenadas por confiança decrescente, o que simplifica a etapa de geração de recomendações.

4.5 Geração de recomendações *Top-N*

A geração de recomendações é separada do cálculo das regras, o que permite reaproveitar o mesmo conjunto de regras para várias consultas sem recalculá-las.

Dada a identificação de um produto, a função `obterRecomendacoes` filtra as regras cujo antecedente corresponde ao produto consultado e retorna as N primeiras que, por já estarem ordenadas por confiança, são as mais fortes. O parâmetro N , fixado em 3, equilibra a relevância das sugestões com a clareza da interface e evita sobrecarregar o usuário com recomendações de baixa confiança.

4.6 API REST

A lógica do sistema é exposta por uma API REST organizada em quatro grupos de rotas, além de um *endpoint* de verificação de integridade. O Quadro 4 sintetiza os pontos de acesso.

Quadro 4 — Endpoints da API REST

Método e rota	Função
GET /health	Verificação de disponibilidade do servidor
GET /api/recomendacoes/:produtoId	Recomendações Top-N para um produto
GET /api/estatisticas	Métricas globais (total de regras, médias de confiança/suporte)
GET /api/validacao	Precision, Recall e F1-Score
GET /api/produtos?q=<termo>	Busca parcial de produtos (autocomplete)

Fonte: elaborada pelo autor (2026).

Cada grupo de rotas delega a lógica aos serviços correspondentes, o que mantém as rotas enxutas e focadas no protocolo HTTP: validação de parâmetros, códigos de *status* e serialização da resposta em JSON. O servidor é configurado com CORS restrito ao domínio do *front-end*, e sua inicialização é separada da definição da aplicação, o que permite que os testes de integração importem a aplicação sem subir uma porta de rede.

4.7 Cache com degradação *graceful*

Como o cálculo das regras percorre todas as transações a cada requisição, introduziu-se uma camada de *cache* em Redis que memoriza os resultados por um período determinado (uma hora para recomendações; trinta minutos para estatísticas,

que variam com mais frequência). A consulta primeiro verifica o cache; em caso de acerto, devolve o resultado memorizado; em caso de falha, calcula, armazena e retorna.


O aspecto distintivo do projeto é a degradação *graceful*: o Redis é tratado como dependência opcional. Caso o servidor de *cache* esteja indisponível, situação comum em ambiente de desenvolvimento, as operações de leitura e escrita no *cache* falham silenciosamente, e o sistema recalcula as regras a cada requisição. Há uma perda de desempenho, mas nunca de precisão ou disponibilidade. Essa decisão reduz a barreira de instalação e adequa-se ao perfil de baixa infraestrutura visado pelo trabalho.

4.8 Interface *web*

A interface, desenvolvida em React com *build* via Vite, materializa-se em um painel (*dashboard*) que reúne as funcionalidades de consulta. Seus principais componentes são:

- Busca de produto com *autocomplete*: à medida que o usuário digita, o componente consulta o *endpoint* de busca parcial e exibe sugestões de produtos correspondentes, o que dispensa o conhecimento do nome exato.
- Cartões de recomendação: para o produto selecionado, apresentam-se as recomendações *Top-N*, cada qual acompanhada de suas métricas de *confidence*, suporte e *lift*, o que torna a sugestão interpretável pela equipe de vendas.
- Gráficos das regras: por meio da biblioteca Chart.js, visualizam-se as regras de maior destaque e a distribuição das métricas, o que confere uma leitura agregada dos padrões descobertos.

Figura 3 — Painel principal do sistema



Fonte: elaborada pelo autor (2026).

No módulo de serviço *front-end*, a comunicação com a API é centralizada e o ambiente de desenvolvimento usa o *proxy* do Vite para encaminhar chamadas ao servidor *Express*, o que evita questões de CORS no desenvolvimento.

4.9 Decisões de projeto e *trade-offs*

No contexto de baixo volume de dados e baixo custo de infraestrutura, tomamos certas decisões e descrevemos as principais abaixo.

A primeira decisão foi extrair apenas pares em vez do Apriori completo. *Apriori* (AGRAWAL; SRIKANT, 1994) e *FP-Growth* (HAN; PEI; YIN, 2000) são amplamente utilizados para mineração de conjuntos de itens de qualquer número. Mas decidimos que limitaríamos a mineração a regras de item um-para-

um. A complexidade do procedimento é $O(n \cdot p^2)$, onde n é o número de transações e p é o número de produtos. Dado o tamanho deste estudo (temos dezenas de transações e produtos), o custo é mínimo, e não queremos ter regras de múltiplos itens com pouco suporte que são necessariamente difíceis de usar. No entanto, se aumentarmos nossa coleta de dados, teremos que considerar generalizar a mineração para conjuntos de itens maiores.

A segunda parte foi o uso de *PostgREST* e não SQL. Queríamos que a operação fosse simples e gratuita e, portanto, menos controle sobre a otimização de consultas, o que é insignificante nesta escala.

A terceira foi tornar o *cache* opcional, não obrigatório. Uma potencial perda de desempenho na ausência de Redis era aceitável em troca de menos complexidade de implantação, em linha com o público-alvo de pequenas empresas.

A quarta foi recalcular as regras na memória a cada solicitação, em vez de manter a tabela de regras pré-calculadas em um estado rotativo (com um *cache* para ajudar). Como os dados transacionais mudam com baixa frequência em uma pequena distribuidora, o *trade-off* favorece a simplicidade e a consistência sobre a antecipação do cálculo.

Essas decisões são consistentes com o objetivo do projeto: fornecer um sistema completo, correto e reproduzível que seja dimensionado para o problema real e não uma solução muito mais robusta em uma escala que o cenário B2B não requer.

5 RESULTADOS E DISCUSSÃO

Este capítulo apresenta e discute os resultados obtidos a partir da aplicação do sistema descrito no Capítulo 4 sobre os dados reais de vendas da Quasar Barber. Começa com a caracterização do conjunto de dados (Seção 5.1), depois analisa as regras de associação descobertas e seu ranking por lift (Seção 5.2), e finalmente sintetiza as métricas globais do conjunto de regras (Seção 5.3). Na Seção 5.4, avaliamos *Precision*, *Recall* e *F1-Score* sob o protocolo de validação cruzada *Leave-One-Out* (LOOCV) e discutimos as limitações do estudo. Nas Seções 5.5 e 5.6, discutimos a conformidade das

regras com o conhecimento do domínio e comparamos os resultados com a hipótese de pesquisa. A Seção 5.7 se encerra com as limitações do estudo.

Este capítulo apresenta e discute os resultados obtidos com a aplicação do sistema descrito no Capítulo 4 sobre os dados reais de venda da Quasar Barber. Inicia-se pela caracterização do conjunto de dados (Seção 5.1), seguida da análise das regras de associação descobertas e de seu ordenamento por *lift* (Seção 5.2) e da síntese das métricas globais do conjunto de regras (Seção 5.3). A Seção 5.4 reporta a avaliação por *Precision*, *Recall* e *F1-Score* sob o protocolo de validação cruzada *Leave-One-Out* (LOOCV) e discute suas limitações. As Seções 5.5 e 5.6 examinam, respectivamente, a aderência das regras ao conhecimento de domínio e o confronto dos resultados com a hipótese de pesquisa. A Seção 5.7 encerra com as limitações do estudo.

5.1 Caracterização do conjunto de dados

Após o pré-processamento discutido na Seção 3.4, o conjunto consiste em 30 transações, 26 clientes e 29 produtos, totalizando 52 itens de venda para o período de 29 de abril a 18 de junho de 2026. Do número total de transações, apenas 14 contêm dois ou mais produtos, e as cestas são úteis para a busca de regras de coocorrência, enquanto as 16 restantes, com um único item, são usadas apenas para o cálculo do suporte individual dos produtos. O Quadro 5 resume os indicadores do conjunto.

Quadro 5 — Caracterização do conjunto de dados

Indicador	Valor
Transações (cestas)	30
Clientes distintos	26
Produtos únicos	29
Itens de venda	52
Transações multi-item ($k \geq 2$)	14
Período de referência	29/04/2026 a 18/06/2026

Fonte: elaborada pelo autor (2026).

A média de itens por transação é de aproximadamente 1,73 produto por cesta, valor coerente com a natureza do comércio B2B de reposição investigado, em que uma parte expressiva dos pedidos visa à reposição de um único produto. Essa esparsidade é a principal característica do cenário e, portanto, a base de toda a análise subsequente: limita o número de regras que podemos extrair; por outro lado, é exatamente a situação onde o filtro colaborativo clássico falha e onde as regras de associação serão testadas (ver seções 1.2 e 2.3).

5.2 Regras descobertas e análise por lift

Submetido o conjunto ao algoritmo de extração (Seção 4.4), com confiança mínima de 0,30 e suporte mínimo de 0,02, foram geradas 44 regras de associação do tipo $A \Rightarrow B$. A Tabela 1 apresenta as dez regras de maior *lift*, indicador que mede o quanto a coocorrência de dois produtos excede o esperado sob a hipótese de independência (Seção 2.2.3).

Tabela 1 — Dez regras de maior lift

#	Antecedente (A)	Consequente (B)	Conf.	Sup.	Lift
1	After Shave 100g – Loção Pós Barba (QOD)	Café Verde Shampoo 220ml (QOD)	1,00	0,033	30,0
2	Café Verde Shampoo 220ml (QOD)	After Shave 100g – Loção Pós Barba (QOD)	1,00	0,033	30,0
3	Silver Boost Shampoo 220ml (QOD)	Bálsamo Fortalecedor de Barba 100g (QOD)	1,00	0,033	30,0
4	Bálsamo Fortalecedor de Barba 100g (QOD)	Silver Boost Shampoo 220ml (QOD)	1,00	0,033	30,0
5	Escova de Disfarce Barber Pro (madeira)	Escovinha de Disfarce Annie 2073	1,00	0,033	15,0
6	Shampoo para Barba 120ml (Fox For Men)	Óleo para Barba Spray 60ml (Fox For Men)	1,00	0,067	15,0
7	Óleo para Barba Spray 60ml (Fox For Men)	Shampoo para Barba 120ml (Fox For Men)	1,00	0,067	15,0
8	Pente de Madeira Bambu Meia-Lua 9,5	Shampoo para Barba 120ml (Fox For Men)	1,00	0,033	15,0
9	Pente de Madeira Bambu Meia-Lua 9,5	Óleo para Barba Spray 60ml (Fox For Men)	1,00	0,033	15,0
10	Maquiagem Capilar Preto 25g (Fox For Men)	Aplicador de Fibra Capilar (Fox For Men)	1,00	0,067	15,0

Fonte: elaborada pelo autor (2026).

Todas as principais regras têm 100% de confiança, o que significa que, sempre que o antecedente foi comprado, o consequente também estava na

mesma cesta. Os valores de *lift* de 15,0 a 30,0 são bastante altos em termos absolutos e sinalizam associações muito mais fortes do que o acaso. Mas é necessária uma leitura cautelosa: nesse desenho, o *lift* de uma regra com confiança 1,0 é igual a $1/\text{support}(B)$. Os consequentes do topo ocorrem em apenas uma ou duas das 30 transações, de modo que seu suporte isolado é mínimo (0,033 ou 0,067) e o *lift* resultante é, por construção, alto. Em outras palavras, os maiores valores de *lift* coincidem com os pares de menor suporte, produtos que apareceram juntos em pouquíssimas cestas. Isso não invalida as regras, mas requer que o *lift* seja interpretado em conjunto com o suporte e o conhecimento do domínio (Seção 5.5) para não superestimar a robustez estatística de coocorrências raras. Esta é precisamente a distinção que a segunda subquestão de pesquisa (Capítulo 1) visa fazer.

5.3 Métricas globais do conjunto de regras

Considerado o conjunto completo das 44 regras, os indicadores agregados são apresentados no Quadro 6.

Quadro 6 — Métricas globais do conjunto de regras

Métrica	Valor médio
Total de regras geradas	44
Confiança média	0,7651 (76,51%)
Suporte médio	0,0439 (4,39%)
<i>Lift</i> médio	12,41

Fonte: elaborada pelo autor (2026).

A confiança média de 76,51% indica que, em média, o antecedente é um forte preditor da presença do consequente entre as regras retidas, o que não é surpreendente, já que o filtro de confiança mínima (0,30) descarta associações fracas. O suporte médio de apenas 4,39% reflete a extensão da esparsidade do conjunto: as regras descrevem padrões reais, mas não são muito frequentes. O *lift* médio de 12,41, muito superior a 1,0, portanto, prova que as associações retidas estão longe da independência estatística, embora, como discutido na

Seção 5.2, o valor seja um tanto inflacionado pelo baixo suporte dos consequentes.

5.4 Avaliação por *Precision*, *Recall* e *F1-Score*

A qualidade preditiva das recomendações foi estimada pelo protocolo de validação cruzada *Leave-One-Out* (LOOCV), descrito na Seção 3.6.2, com o esquema de ocultação de um item e $N = 3$ recomendações por subteste. Das 30 transações, as 14 multi-item foram efetivamente avaliáveis, o que gerou, no total, 36 subtestes. O Quadro 7 apresenta os resultados.

Quadro 7 — Resultados da validação cruzada *Leave-One-Out* (LOOCV)

Métrica	Valor
Transações avaliadas	14
Subtestes acumulados	36
<i>Precision</i> média	0,2639 (26,39%)
<i>Recall</i> médio	0,4444 (44,44%)
<i>F1-Score</i> médio	0,3194 (31,94%)

Fonte: elaborada pelo autor (2026).

A interpretação desses valores deve começar a partir do teto estrutural de *Precision* discutido na Seção 3.6.3. Como cada subteste esconde um único produto e o sistema sugere até três, a *Precision* máxima em um acerto é $1/3 \approx 0,33$. Assim, a *Precision* média (0,2639) está próxima do seu limite teórico superior e não deve ser interpretada como se as sugestões estivessem 73% erradas: é simplesmente uma consequência aritmética do design da avaliação e não uma qualidade inferior das sugestões. Por essa razão, *Recall* e *F1-Score* são, neste estudo, os indicadores mais informativos.

O *Recall* médio de 44,44% significa que, em 16 dos 36 subtestes, o produto deliberadamente ocultado da cesta foi recuperado entre as três recomendações, ou seja, em quase metade dos casos o sistema completou a cesta corretamente a partir dos produtos restantes. Para um conjunto de apenas 14 transações avaliáveis, sem qualquer sinal de avaliação ou nota de produto e dependente exclusivamente da coocorrência, esse desempenho é expressivo. O *F1-Score* de 31,94%, que é a

média harmônica entre as duas métricas, reúne esse comportamento e é naturalmente reduzido pelo teto de Precision.

5.4.1 Confronto com o *holdout* simples

Por outro lado, o resultado do *holdout* por divisão de treino/teste de 80/20 é usado apenas como referência e o procedimento principal por nossas razões discutidas na Seção 3.6.1. A fragilidade desse número é exatamente o problema que antecipamos: uma estimativa apoiada por três casos é instável e não confiável, enquanto o LOOCV cobre todas as transações e coleta 36 subtestes que são uma medida muito mais robusta para o mesmo conjunto de dados. A superioridade metodológica da LOOCV em conjuntos pequenos fica, assim, evidenciada empiricamente.

5.5 Aderência ao conhecimento de domínio

Além da informação quantitativa, a avaliação de um sistema de recomendação também é verificar se as regras encontradas são apropriadas para o especialista em negócios, neste caso, o próprio autor, na condição de proprietário da distribuidora. Olhando para as regras com o maior *lift* (Tabela 1) vemos três padrões que são comuns no uso comercial:

1. Reciprocidade funcional na rotina de barbear. As regras que associam *shampoo* para barba, óleo para barba, bálsamo e loção pós-barba (regras 1 a 4, 6 a 9) são todos produtos da mesma rotina de cuidados e são frequentemente vendidos juntos para barbearias. Esses são os tipos de associações que um vendedor experiente faria intuitivamente e que o sistema obteve apenas a partir dos dados.
2. Coerência de marca e linha de produtos. Há uma forte coocorrência entre linhas de produtos da mesma marca, com linhas QOD (regras 1 a 4) e *Fox For Men* (regras 6 a 10). Isso reflete o comportamento real de compra das barbearias que tendem a padronizar fornecedores e comprar kits com a mesma linha.
3. Associação por categoria de acessório. A regra que liga a *Escova de Disfarce Barber Pro* à *Escovinha de Disfarce Annie* (regra 5) capta a

compra conjunta de acessórios de função equivalente, padrão típico de reposição de estoque.

A aderência observada sugere que as regras não são artefatos incorretos, mas refletem relações comerciais plausíveis, condição necessária para que a ferramenta seja útil à equipe de vendas. Ressalva-se, contudo, que a baixa frequência absoluta dessas coocorrências (Seção 5.2) impõe que as recomendações sejam tratadas como sugestões de apoio à decisão, e não como prescrições automáticas.

5.6 Confronto com a hipótese de pesquisa

Retoma-se aqui a hipótese formulada na Seção 1.3:

H1: regras de associação com $\text{confidence} \geq 0,30$ e $\text{support} \geq 0,02$, ranqueadas por *lift*, produzem recomendações de *cross-sell* coerentes com o conhecimento de domínio da distribuidora, mesmo em um conjunto de dados reduzido.

H0: no caso de menor volume de vendas, as regras geradas são indistinguíveis da coocorrência aleatória e não superam a recomendação baseada apenas na popularidade do produto (*baseline* de popularidade).

Os resultados sugerem não rejeitar H1. As 44 regras que foram extraídas sob os limiares tiveram *lift* médio de 12,41, bem acima de 1,0, que seria esperado para coocorrências aleatórias, e as regras mais dominantes mostraram bom entendimento do domínio (Seção 5.5). Para a hipótese nula, os resultados do sistema em LOOCV (*Recall* de 44,44%) mostram que é de fato preditivo: um *baseline* de popularidade que recomendaria os produtos mais vendidos independentemente do anterior não recuperaria os pares específicos de complementaridade observados, já que os produtos da regra de melhor *lift* não estão em geral no maior volume individual. Portanto, as regras carregam alguma informação além da frequência, o que não é verdade para H0. Esta conclusão deve ser temperada pelo fato de que verificamos o acima com 14 transações, o que é suficiente para mostrar a possibilidade de sucesso da abordagem na situação que investigamos, mas não em geral para alguma generalização estatística, limitação tratada na seção seguinte.

5.7 Limitações do estudo

A principal limitação dos resultados é o volume reduzido de dados: 30 transações, das quais apenas 14 são multi-item. Embora este seja o tamanho razoável para o período de tempo e tamanho da empresa, limita o número de regras a serem extraídas, torna as métricas sensíveis a casos únicos e aumenta os valores de *lift* de coocorrências raras (Seção 5.2). À medida que o histórico do distribuidor aumenta, esperamos que as estimativas sejam mais estáveis e mais robustas para as regras.

Uma segunda limitação decorre de uma decisão de projeto deliberada (Seção 4.9): a restrição a regras de um item no antecedente e um no consequente. Não conseguimos observar padrões legítimos onde três ou mais produtos foram comprados juntos. A generalização para *itemsets* de tamanho maior (total *Apriori* ou *FP-Growth*) será incluída em trabalhos futuros no caso do volume de dados que seja viável.

Por fim, o teto estrutural da *Precision* imposto pelo esquema de ocultação de um único item (Seção 3.6.3) limita a comparação dos números absolutos deste trabalho com os de outros estudos que usaram abordagens diferentes para avaliar. Portanto, a interpretação privilegiou *Recall* e *F1-Score* e contextualizou a *Precision* à luz do seu limite teórico. Essas limitações invalidam o estudo, mas delimitam com honestidade o seu alcance e apontam direções concretas de continuidade, retomadas na conclusão (Capítulo 6).

6 CONCLUSÃO

Este trabalho investigou se é possível fazer recomendações de produtos úteis e estatisticamente relevantes para um pequeno distribuidor B2B usando regras de associação obtidas a partir do histórico de vendas, mesmo na ausência de um alto volume de transações. Para responder a essa pergunta, foi desenvolvido e avaliado um sistema com dados reais da Quasar Barber. Nesta seção, retoma as contribuições do estudo (Seção 6.1), responde de forma direta à pergunta de pesquisa (Seção 6.2) e aponta os caminhos de continuidade (Seção 6.3).

6.1 Síntese das contribuições

O trabalho produziu um artefato funcional e reproduzível, conforme o paradigma de *Design Science Research* adotado no Capítulo 3. O sistema abrange todas as etapas, desde o carregamento e pré-processamento de dados até a interface de consulta web (algoritmo de extração de regras, API REST e camada de validação). A arquitetura foi dimensionada para o tamanho de uma pequena empresa, com ferramentas gratuitas ou de baixo custo, e sem dependência de infraestrutura de *Big Data*.

No plano empírico, a aplicação em dados reais produziu 44 regras de associação a partir de 30 transações, com confiança média de 76,51% e *lift* médio de 12,41. As regras mais populares são claramente consistentes com a prática comercial da distribuidora, ao agrupar produtos de uma mesma rotina de cuidado ou de uma mesma linha de marca. Isso indica que algoritmo foi capaz de identificar relações reais de compra, não apenas coincidências para uma organização.

O estudo também contribui no plano metodológico. Ao constatar que o *holdout* 80/20 deixava apenas três transações avaliáveis, o estudo também contribui no nível metodológico. Uma vez que descobre que a retenção 80/20 deixou apenas três transações avaliadas, o trabalho adotou a validação cruzada *Leave-One-Out* como a abordagem principal e documentou, com números, por que isso é mais apropriado para conjuntos pequenos. A discussão sobre o teto estrutural da Precision, que é fixado em $1/N \approx 0,33$ ao ocultar um item, também é um registro útil, pois explica como interpretar as métricas sem confundir uma limitação do design de avaliação com baixa qualidade das recomendações.

6.2 Resposta à pergunta de pesquisa

A questão que orientou este trabalho foi se regras de associação sozinhas podem produzir recomendações significativas em um cenário B2B de baixo volume. A resposta é afirmativa, com algumas ressalvas.

As evidências favorecem a hipótese H1. As regras preservadas mostraram um *lift* acima de 1,0, o que teria desqualificado a hipótese de coocorrência aleatória, e o sistema recuperou o produto oculto em 16 de 36 subtestes de validação cruzada, um *Recall* de 44,44%. Para um conjunto sem notas de produtos e sem uma matriz densa de usuário-item, onde o filtro colaborativo clássico não funciona, isso sustenta a viabilidade da abordagem. As regras também não são apenas sobre o número de vendas, mas os pares com o maior *lift* não coincidem com os produtos de maior volume individual, o que enfraquece a hipótese nula de que um *baseline* de popularidade bastaria.

A ressalva é a escala. A conclusão se baseia em 14 transações de múltiplos itens para mostrar que o método realmente funciona, mas não autoriza uma generalização estatística ampla. O baixo suporte das regras e como o valor do *lift* dessas coocorrências raras aumenta reforça que as recomendações devem ser tratadas como suporte à decisão para a equipe de vendas, não como prescrições automáticas.

6.3 Trabalhos futuros

O escopo do estudo é a continuação mais natural deles. O primeiro é o acúmulo de mais dados. À medida que a história da Quasar Barber continua, espera-se métricas mais robustas e um suporte mais sólido para as regras. Isso levaria a uma reavaliação muito mais segura dos limiares de confiança e suporte. O segundo é a generalização do algoritmo para *itemsets* de maior tamanho. A restrição a regras de itens um-para-um foi decisão consciente, justificada pelo volume atual (Seção 4.9). Com um conjunto maior, valeria a pena implementar todo o *Apriori* ou *FP-Growth* para ver se há padrões de compra de três ou mais produtos juntos.

O terceiro é a colocação do sistema em produção, integrado ao fluxo de vendas do distribuidor, para que as recomendações sejam entregues à equipe no momento do pedido. É a partir daí que uma avaliação de impacto real do sistema por meio de um teste A/B, começa a se abrir e comparar o *ticket* médio dos pedidos apoiados por recomendações com aqueles sem elas. Essa medida fecharia a lacuna entre a relevância estatística verificada neste trabalho e o efeito econômico que motivou a pesquisa.

REFERÊNCIAS

- ADOMAVICIUS, G.; TUZHILIN, A. Toward the next generation of recommender systems: a survey of the state-of-the-art and possible extensions. *IEEE Transactions on Knowledge and Data Engineering*, v. 17, n. 6, p. 734-749, 2005.
- AGGARWAL, C. C. *Recommender systems: the textbook*. Cham: Springer, 2016.
- AGRAWAL, R.; IMIELIŃSKI, T.; SWAMI, A. Mining association rules between sets of items in large databases. In: ACM SIGMOD INTERNATIONAL CONFERENCE ON MANAGEMENT OF DATA, 1993, Washington, D.C. *Proceedings [...]*. New York: ACM, 1993. p. 207-216.
- AGRAWAL, R.; SRIKANT, R. Fast algorithms for mining association rules. In: INTERNATIONAL CONFERENCE ON VERY LARGE DATA BASES (VLDB), 20., 1994, Santiago, Chile. *Proceedings [...]*. San Francisco: Morgan Kaufmann, 1994. p. 487-499.
- BRIN, S.; MOTWANI, R.; ULLMAN, J. D.; TSUR, S. Dynamic *itemset* counting and implication rules for market basket data. In: ACM SIGMOD INTERNATIONAL CONFERENCE ON MANAGEMENT OF DATA, 1997, Tucson. *Proceedings [...]*. New York: ACM, 1997. p. 255-264.
- GIL, A. C. *Como elaborar projetos de pesquisa*. 6. ed. São Paulo: Atlas, 2017.
- HAHSLER, M.; GRÜN, B.; HORNIK, K. arules — a computational environment for mining association rules and frequent item sets. *Journal of Statistical Software*, v. 14, n. 15, p. 1-25, 2005.
- HAN, J.; KAMBER, M.; PEI, J. *Data mining: concepts and techniques*. 3. ed. Waltham: Morgan Kaufmann, 2011.
- HAN, J.; PEI, J.; YIN, Y. Mining frequent patterns without candidate generation. In: ACM SIGMOD INTERNATIONAL CONFERENCE ON MANAGEMENT OF DATA, 2000, Dallas. *Proceedings [...]*. New York: ACM, 2000. p. 1-12.
- HEVNER, A. R.; MARCH, S. T.; PARK, J.; RAM, S. Design science in information systems research. *MIS Quarterly*, v. 28, n. 1, p. 75-105, 2004.
- KOREN, Y.; BELL, R.; VOLINSKY, C. Matrix factorization techniques for recommender systems. *Computer*, v. 42, n. 8, p. 30-37, 2009.
- LINDEN, G.; SMITH, B.; YORK, J. Amazon.com recommendations: item-to-item collaborative filtering. *IEEE Internet Computing*, v. 7, n. 1, p. 76-80, 2003.
- MARCONI, M. de A.; LAKATOS, E. M. *Fundamentos de metodologia científica*. 8. ed. São Paulo: Atlas, 2017.
- MORAES, Francine Machado. *Recomendação de produtos através do método de Market Basket Analysis aplicado ao cenário de Big Data*. Orientador: Tiago Thompsons Primo. 2023. 66 f. Dissertação (Mestrado em Ciência da Computação) —

Centro de Desenvolvimento Tecnológico, Universidade Federal de Pelotas, Pelotas, 2023.

PEFFERS, K.; TUUNANEN, T.; ROTHENBERGER, M. A.; CHATTERJEE, S. A design science research methodology for information systems research. *Journal of Management Information Systems*, v. 24, n. 3, p. 45-77, 2007.

POWERS, D. M. W. Evaluation: from precision, recall and F-measure to ROC, informedness, markedness and correlation. *Journal of Machine Learning Technologies*, v. 2, n. 1, p. 37-63, 2011.

RESNICK, P.; VARIAN, H. R. Recommender systems. *Communications of the ACM*, v. 40, n. 3, p. 56-58, 1997.

RICCI, F.; ROKACH, L.; SHAPIRA, B. (Eds.). *Recommender systems handbook*. 2. ed. New York: Springer, 2015.

SARWAR, B.; KARYPIS, G.; KONSTAN, J.; RIEDL, J. Item-based collaborative filtering recommendation algorithms. In: INTERNATIONAL CONFERENCE ON WORLD WIDE WEB (WWW), 10., 2001, Hong Kong. *Proceedings [...]*. New York: ACM, 2001. p. 285-295.

SCHAFER, J. B.; KONSTAN, J. A.; RIEDL, J. E-commerce recommendation applications. *Data Mining and Knowledge Discovery*, v. 5, n. 1-2, p. 115-153, 2001.

SCHONHORST, Gustavo Bonnard. *Mineração de regras de associação aplicada à modelagem dos dados transacionais de um supermercado*. 2010. Dissertação (Mestrado) — Universidade Federal de Itajubá, Itajubá, 2010.

TAN, P.-N.; STEINBACH, M.; KUMAR, V. *Introduction to data mining*. Boston: Pearson Addison-Wesley, 2005

YIN, R. K. *Estudo de caso: planejamento e métodos*. 5. ed. Porto Alegre: Bookman, 2015.